

Pretvorba satelitske snimke u Google kartu

Marko Domagoj Benković Helena Marcius
Mihovil Stručić

27. travnja 2022.

Uvodni opis problema

U današnje doba, digitalne karte koriste se svakodnevno, prvenstveno u svrhu navigacije. Koriste ih vozači taxija i autobusa, dostavljačke službe, dostavljači hrane, vojska, vozila bez vozača (npr. bespilotne letjelice) te pojedinci za navigaciju po gradu ili u automobilu. Zbog česte upotrebe karata, bitno je da su karte kvalitetne i detaljne, odnosno da čim bolje opisuju stvarni prostor. Želimo da je na kartama označeno čim više objekata i cesta, da je prikazan reljef te da su udaljenosti i veličine na karti proporcionalne onima u stvarnosti.

Međutim, izrada karata može biti vrlo skupa i cijena raste proporcionalno s obzirom na kvalitetu i detaljnost karte. Zbog toga se žele razviti načini koji omogućuju jeftiniju izradu karata, a da opet te karte budu što kvalitetnije. Jedan od tih načina koristi metode strojnog učenja, točnije neuronske mreže. Upravo ćemo se ovim problemom baviti u našem projektu. Koristeći određenu vrstu GAN-a, odnosno generativne suparničke mreže, iz satelitske snimke Zemljine površine, prvenstveno dijelova grada, stvorit ćemo kartu područja prikazanog na satelitskoj snimci. Pošto su Google karte trenutno jedne od najkorištenijih karata, stvorit ćemo upravo kartu koja bi se prikazala na Google kartama.

Cilj i hipoteze istraživanja problema

Kao što smo već spomenulu, cilj nam je generirati Google karte iz satelitskih snimaka. Želimo da karte budu što preciznije i detaljnije. Pretpostavljamo

da bi našem modelu probleme mogle stvarati snimke na kojima je više detalja i boja, kao što su slike mreže cesta ili gradskih blokova, dok bi slike npr. vode ili zelenih površina trebale biti jednostavnije za generiranje karte.

Pregled dosadašnjih istraživanja

Ovaj problem počeo se nedavno proučavati te je većina članaka i istraživanja na ovu temu novijeg datuma. U [5] obrađen je upravo ovaj problem i korišten je isti *dataset* koji ćemo i mi koristiti. Problem je riješen korištenjem *Conditional GAN-a*, skraćeno *CGAN*.

U [6] se proučava općenitiji problem, takozvani *Image to Image Translation*. Uz generiranje mapa iz satelitskih snimki, također se radi generiranje slika cipela iz crteža, stvaranje slika u boji iz crno bijelih slika te pretvorba slika slikanih po danu u slike koji izgledaju kao da su slikane noću. Koristi se također *CGAN*, a za sve probleme korišten je isti model, samo je treniran na različitim podacima. Korišteni *dataset* je već spomenuti *pixtopix*.

U [7] korišten je takozvani *DualGAN* model koji koristi slike bez labela. Također se proučava općeniti problem generiranja slika. U nekim se slučajevima *DualGAN* pokazao boljim od *CGAN-a*, međutim kod pretvaranja satelitske snimke u kartu boljim se pokazao *CGAN* koji je generirao preciznije i detaljnije mape.

U [8] korišten je *CycleGAN* koji radi u oba smjera. Konkretnije, može pretvoriti satelitsku snimku u kartu i kartu u satelitsku snimku. Također se može koristiti i na nesparenim *dataset*-ovima u kojima imamo ulazne slike i izlazne slike, ali nije određeno koji izlaz odgovara kojem ulazu.

Materijali, metodologija i plan istraživanja

Dataset koji ćemo koristiti sastoji se od satelitskih snimaka dijelova New Yorka i njihovih Google Map "parova". *Dataset* se može pronaći na [2]. *Dataset* je podijeljen na dva skupa slika: *training set* i *validation set*. *Training set* sadrži 1096 slika, a *validation set* sadrži 1098 slika. Na svakoj slici, lijeva polovica slike prikazuje satelitsku snimku, a desna polovica prikazuje Google kartu. Sve slike prikazuju dijelove New Yorka. Slike su dimenzija 1200×600 piksela. Napomenimo još da su slike dio većeg dataseta s Kaggle-a zvanog *pixtopix* koji se može pronaći na [1].

Sve ćemo slike prvo skalirati i podijeliti na dva dijela, tako da dobijemo posebno satelitsku snimku i posebno Google kartu. Za naš model izgradit ćemo *CGAN* koji se sastoji od dvije neuronske mreže: generator i diskriminator. Generator dobiva satelitsku snimku i stvara kartu. Diskriminatoru se daje generirana karta i očekivana karta (diskriminator ne zna koja je koja). Diskriminator odlučuje je li generirana karta očekivana karta ili generirana. Model ćemo izraditi koristeći *Python* biblioteke *Keras* i *Tenserflow*. Na kraju ćemo naš model isprobati na satelitskim snimkama iz *dataset*-ova [3] i [4] za koje nemamo već gotovu Google kartu. Naše rezultate usporedit ćemo s rezultatima dosadašnjih istraživanja koje smo ranije opisali.

Očekivani rezultati predloženog projekta

Očekujemo da će naš model uspješno generirati karte iz satelitskih snimaka New Yorka te da će rezultati biti slični onima iz ranijih istraživanja. Također očekujemo i da će model moći generirati karte iz proizvoljnih satelitskih snimaka. Uz rješavanje ovog problema, cilj nam je i upoznati se sa *CGAN*-om.

Literatura

- [1] URL: <https://www.kaggle.com/datasets/vikramtiwari/pix2pix-dataset>.
- [2] URL: https://drive.google.com/file/d/1s5a2UeJR4H_KJ-nV4NmRMkBHr3zn20Tf/view.
- [3] URL: <https://www.kaggle.com/datasets/balraj98/deepglobe-road-extraction-dataset>.
- [4] URL: <https://www.kaggle.com/datasets/balraj98/deepglobe-land-cover-classification-dataset>.
- [5] Vaishali Ingale, Rishabh Singh i Pragati Patwal. „Image to Image Translation: Generating Maps From Satellite Images”. (2019.). URL: <https://arxiv.org/pdf/2105.09253.pdf>.
- [6] Phillip Isola i dr. „Image-to-Image Translation with Conditional Adversarial Networks”. (2018.). URL: <https://arxiv.org/pdf/1611.07004.pdf>.

- [7] Zili Yi i dr. „DualGAN: Unsupervised Dual Learning for Image-to-Image Translation”. (2018.). URL: <https://arxiv.org/pdf/1704.02510.pdf>.
- [8] Jun-Yan Zhu i dr. „Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks”. (2020.). URL: <https://arxiv.org/pdf/1703.10593.pdf>.